

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ  
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ  
«НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ  
"ВЫСШАЯ ШКОЛА ЭКОНОМИКИ"»

Факультет компьютерных наук

Семенюк Александр Александрович

**ВЫЯВЛЕНИЕ И АНАЛИЗ ВИЗУАЛЬНЫХ ПАТТЕРНОВ В  
АРХИТЕКТУРЕ ДЛЯ ОПРЕДЕЛЕНИЯ ПЕРИОДА ПОСТРОЙКИ И  
АРХИТЕКТУРНОГО СТИЛЯ МЕТОДАМИ ГЛУБИННОГО  
ОБУЧЕНИЯ**

Выпускная квалификационная работа  
по направлению подготовки 01.04.02 Прикладная математика и информатика  
образовательная программа «Аналитика больших данных»

Научный руководитель,  
преподаватель факультета  
компьютерных наук НИУ ВШЭ,  
Блуменау Марк Ильич

Москва 2026

# Аннотация

Выпускная квалификационная работа посвящена задаче автоматического определения атрибутов зданий (тип, год постройки, материал отделки и конструкции, этажность) по уличным фотографиям фасадов методами глубинного обучения.

В рамках работы сформирован набор данных из 16 113 изображений с разметкой по восьми признакам. Сырая автоматическая разметка получена с применением фреймворка OpenFACADES и скорректирована вручную в среде CVAT (Computer vision annotation tool). Проведён исследовательский анализ данных, выявивший критический дисбаланс классов, артефакты автоматической разметки и большое количество искажений на уличных фото.

Реализованы два решения: референсное на основе ResNet-50 [6] (точность классификации типов зданий 71.8%) и итоговое многозадачное на основе ConvNeXt-Base [24], одновременно предсказывающее все восемь атрибутов. Итоговая модель продемонстрировала точность классификации типов зданий 72.9%, материалов отделки — 83.2%, материалов конструкции — 86.1%, среднюю абсолютную ошибку предсказания этажности 1.24 этажа ( $R^2 = 0.868$ ). С помощью Grad-CAM [12] выполнена интерпретация решений модели, подтвердившая, что модель опирается на архитектурно значимые элементы фасада.

Работа содержит 13 рисунков, 1 таблицу, 24 источника.

Ключевые слова: глубокое обучение, компьютерное зрение, свёрточные нейронные сети, многозадачное обучение, классификация изображений, архитектура, здания.

# Содержание

|          |                                                                         |           |
|----------|-------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Введение</b>                                                         | <b>4</b>  |
| <b>2</b> | <b>Обзор литературы</b>                                                 | <b>4</b>  |
| 2.1      | Обзор существующих решений . . . . .                                    | 4         |
| 2.2      | Обзор источников для формирования датасета . . . . .                    | 8         |
| <b>3</b> | <b>Исследовательский анализ данных обучающей выборки</b>                | <b>9</b>  |
| 3.1      | Сбор и разметка данных . . . . .                                        | 9         |
| 3.2      | Анализ пространственных свойств снимков . . . . .                       | 9         |
| 3.3      | Анализ распределения назначений зданий . . . . .                        | 11        |
| 3.4      | Анализ распределения материалов отделки и несущих конструкций . . . . . | 13        |
| 3.5      | Анализ этажности и поиск ошибочных значений . . . . .                   | 14        |
| 3.6      | Статистика по годам постройки . . . . .                                 | 16        |
| 3.7      | Выводы по итогам исследовательского анализа данных . . .                | 17        |
| <b>4</b> | <b>Референсное решение (baseline)</b>                                   | <b>18</b> |
| 4.1      | Выбор модели . . . . .                                                  | 18        |
| 4.2      | Предобработка данных и обучение модели . . . . .                        | 19        |
| 4.3      | Результаты baseline-модели . . . . .                                    | 20        |
| 4.4      | Выводы по результатам baseline-модели . . . . .                         | 23        |
| <b>5</b> | <b>Предсказание множественных признаков</b>                             | <b>24</b> |
| 5.1      | Выбор модели . . . . .                                                  | 24        |
| 5.2      | Результаты многозадачного обучения . . . . .                            | 26        |
| 5.2.1    | Определение типа здания . . . . .                                       | 27        |
| 5.2.2    | Материалы отделки и конструкции . . . . .                               | 29        |
| 5.3      | Интерпретация решений модели с помощью Grad-CAM . . .                   | 30        |
| 5.3.1    | Проблемные классы . . . . .                                             | 31        |
| 5.3.2    | Лучший класс . . . . .                                                  | 32        |
| 5.3.3    | Классификация материалов . . . . .                                      | 33        |

|                                                       |           |
|-------------------------------------------------------|-----------|
| 5.4 Выводы по результатам Multi-Task модели . . . . . | 33        |
| <b>6 Заключение</b>                                   | <b>35</b> |
| <b>Список литературы</b>                              | <b>38</b> |

# 1 Введение

Актуальность темы обусловлена стабильно растущим интересом к цифровому документированию архитектурного наследия, а также внедрению инструментов на основе машинного обучения и искусственного интеллекта в задачи градостроительного учета, исторических исследований и инженерного анализа.

Задача автоматического определения периода постройки и архитектурного стиля относится к области компьютерного зрения и глубокого обучения и сопряжена с проблемами формирования репрезентативного набора данных, а также выбора и адаптации модели для классификации изображений. Также задача осложняется высокой изменчивостью внутри одного типа зданий, так как здания одного назначения могут иметь принципиально разный дизайн и этажность, а найденные изображения зачастую содержат перспективные искажения и посторонние элементы, заслоняющие фасад.

## 2 Обзор литературы

### 2.1 Обзор существующих решений

Ранние подходы к анализу изображений опирались на извлечение признаков вручную: SIFT (масштабно-инвариантная трансформация признаков) [1], HOG (гистограммы направленных градиентов) [2] и классификацию с помощью традиционных алгоритмов машинного обучения, например метода опорных векторов (SVM) или случайного леса (Random Forest). Прорывным решением стало внедрение сверточных нейронных сетей (СНС).

Успех современных архитектур стал возможен благодаря развитию таких моделей как LeNet-5 [3] и AlexNet [4]. LeNet-5 в 1998 году продемонстрировала практическую эффективность СНС, достигнув точности 99.05% в классификации рукописных цифр на датасете MNIST (Modified National Institute of Standards and Technology — модифицированная база рукописных

цифр Национального института стандартов и технологий США) [3] и доказала работоспособность принципов глубокого обучения для компьютерного зрения. AlexNet в 2012 году радикально улучшил результат на крупнейшем на тот момент соревновании на датасете ImageNet, снизив долю ошибок на 15.3% и опередив ближайшего конкурента на 10.8% [4]. Указанные выше модели продемонстрировали способность автоматически извлекать иерархические визуальные паттерны, что дало толчок к дальнейшему развитию подобных моделей.

Одним из первых примеров применения глубоких нейронных сетей с методами визуальной интерпретации является работа группы исследователей из Национального университета Колумбии в области медицинской диагностики [5]. Предложенная архитектура модели с интерпретируемым слоем, визуализирующим области внимания модели, методологически интересна для задач анализа паттернов архитектурных стилей, т.к. необходимо глубокое понимание причин присвоения того или иного архитектурного стиля. Хотя фундаментальные исследования в области интерпретируемости моделей, например графики частичной зависимости, начались значительно раньше, именно с ростом популярности СНС подобные подходы получили широкое распространение.

В период 2020–2024 годов СНС, такие как ResNet [6], EfficientNet [7] и VGG [8], стали золотым стандартом для классификации изображений. Исследование Demir G. и соавторов в 2021 году подтвердило эффективность СНС для классификации визуальных паттернов в объектах искусства [9].

Анализ Корчагина В.Д. в 2023 году показал, что наиболее перспективным направлением является развитие трансформеров для компьютерного зрения (Vision Transformers, ViT [10]), которые используют механизм внимания для анализа глобального контекста изображения, а также гибридных решений с СНС [11]. Рост сложности моделей повышает важность развития интерпретируемых решений, таких как Grad-CAM (тепловые карты внимания на основе градиентов) [12] и SHAP (аддитивные объяснения Шепли) [13].

Sun M., Zhang F. и соавторы в 2022 году продемонстрировали, что с использованием глубокой сверточной сети (DCNN) возможно определить историческую эпоху постройки зданий по уличным фотографиям и смогли добиться точности в 81.09% [14]. Однако в 2023 году Ху Н. и соавторы продемонстрировали более комплексный подход в масштабе городской застройки Китая, применив Faster R-CNN (Более быстрая сверточная нейронная сеть на основе областей) [15] для обнаружения и классификации 22 стилей архитектуры, достигнув высокого Recall (полноты) (80.91%), но умеренного Precision (точности) (57.8%) [16], что характеризует задачу определения архитектурного стиля в реальной городской среде как достаточно сложную.

Как было отмечено в работе Корчагина В.Д., перспективным направлением является развитие гибридных решений с СНС [11], так в 2025 году были опубликованы результаты исследования, где была использована модель HistoNet для классификации изображений исторических мест по архитектурным признакам, представляющая собой гибридный фреймворк. Модель использует СНС для извлечения локальных признаков, механизмы внимания Transformers для анализа глобального контекста изображения, а также использует модель пространства состояний Mamba [17] для обеспечения линейной вычислительной сложности, что значительно эффективнее квадратичной сложности классических Transformers. На датасетах Architectural Heritage Elements (Элементы архитектурного наследия) и Historical Building Recognition (Распознавание исторических зданий) модель достигла точности 95.66% и 96.46% соответственно, значительно превосходя базовые модели (VGG16 [8], ResNet50 [6]), что в целом характеризует решение как SOTA-модель для данной задачи. Важным новшеством стало внедрение механизмов на основе SHAP [13] для генерации атрибуции на уровне пикселей, что позволило валидировать решения модели [18].

Помимо развития отдельных моделей-классификаторов в 2025 году был представлен фреймворк OpenFACADES, представляющий собой открытую среду для получения сведений о зданиях на основе уличных снимков [19]. Данный фреймворк позволяет извлекать такие параметры как: этажность,

предположительный материал конструкций, назначение и возраст с использованием больших зрительно-языковых моделей (VLM). Проблемой данного решения является отсутствие в открытом доступе экспертно-размеченного обучающего набора данных, что при общей изменчивости архитектурных стилей, дополнительно негативно сказывается на точности.

Еще один практический пример — использование методов глубокого обучения для решения инженерной задачи по автоматизации создания моделей сейсмического риска. В работе приводится сравнение CNN (ResNet [6]) и Transformers (ViT [10], DINOv2) на задаче классификации атрибутов зданий по публичному датасету Alvalade, размеченному по таксономии Global Earthquake Model. Средняя точность достигает 57%, также авторы заметили, что возраст здания и материал постройки дают лучшие результаты в сравнении с изображениями [20], однако это не отменяет жизнеспособность данного подхода.

Одним из актуальных направлений также являются генеративные модели такие как GANs (генеративно-сопоставительные), Diffusion Models (диффузионные модели) в анализе архитектуры. В исследовании выявлен разрыв между генерируемыми растровыми изображениями и общепринятой практикой в САПР (Системы Автоматизированного Проектирования), где пользователь работает с редактируемой геометрией. Таким образом, исследование задает вектор для дальнейшего развития генеративных моделей в строительстве [21].

Подытожить представленный обзор можно тем, что основной тренд применения глубокого обучения в сфере архитектуры и строительства сместился с академических к практическим задачам, которые преимущественно сводятся к решению узконаправленных вопросов, например к оценке сейсмических рисков. Также присутствуют направления исследований в области генеративного ИИ, призванные облегчить или заменить труд проектировщиков. В общих чертах, направление является актуальным для исследований, а существующие классификаторы далеки от идеальной точности, если речь не идет о предварительно подготовленных датасетах.



## 2.2 Обзор источников для формирования датасета

1. WikiArt.org — одна из крупнейших баз данных произведений искусства, содержащая раздел «Архитектура» с изображениями, размеченными стилем, датой создания и автором с возможностью фильтрации по целевым меткам. База охватывает большой исторический период, а метки имеют высокую степень достоверности. Есть возможность доступа через API.
2. Rijksmuseum API (аналоги) — государственный музей Нидерландов, есть возможность получения изображений по ключевым словам. Базы данных музеев позволят обогатить датасет исторической архитектурой.
3. Google Arts & Culture — платформа с музеями-партнерами, большой объем данных об экспонатах, в том числе — изображения архитектуры, однако, отсутствует доступ через API, требуется предобработка, выделение объектов архитектуры из общего массива.
4. Flickr API — хостинг изображений с геометками и пользовательскими тегами. Можно выполнить поиск по ключевым словам-меткам, однако достоверность пользовательских тегов может быть под сомнением. Достоверность меток без предобработки и ручной разметки будет сомнительной, а датасет — плохо пригоден для обучения модели.
5. Cities and Buildings Database — обширная коллекция оцифрованных изображений зданий и городов со всего мира, собранная Университетом Вашингтона. Каждое изображение имеет метки: стиль, дата постройки, город, архитектор, материалы.

## 3 Исследовательский анализ данных обучающей выборки

### 3.1 Сбор и разметка данных

Формирование обучающей выборки осуществлено с применением открытого фреймворка OpenFACADES [19], что позволило в сжатые сроки получить первичную разметку для значительного объема данных, однако, как отмечено в литературном обзоре, отсутствие проверенного специалистами обучающего набора данных и общая изменчивость архитектурных стилей обуславливают наличие ошибок в автоматических метках.

Для повышения достоверности разметки выполнена ручная проверка и корректировка аннотаций, полученных с помощью фреймворка. Корректировка разметки произведена с помощью открытого программного комплекса CVAT (Computer Vision Annotation Tool) — средства разметки изображений, широко применяемого в задачах компьютерного зрения. В ходе корректировки автоматических меток были устранены аномальные значения этажности и некорректные типы зданий. Итоговый датасет содержит 16113 изображений с 11 информативными признаками, ключевыми являются: `type` (тип, назначение здания), `age` (предполагаемый год постройки), `surface_mat` (материал отделки), `constr_mat` (материал несущих конструкций) и `floors` (этажность). Для признаков, определяющих материалы и тип предусмотрены альтернативные метки, призванные сгладить неоднозначность восприятия тех или иных построек.

### 3.2 Анализ пространственных свойств снимков

Визуальный анализ изображений собранного датасета показал основные проблемы, такие как перспективные искажения (Рисунок 1), а также наличие элементов растительности, автомобилей и иных объектов окружающей среды, частично перекрывающих фасад рассматриваемого здания. Подоб-

ные проблемы типичны для уличной съемки зданий и, как отмечено в работе М. Sun и соавторов, являются основным препятствием для уверенного распознавания объектов в условиях плотной застройки [14].

Изучение геометрических характеристик изображений (Рисунок 2) выявило неоднородность разрешений. Ширина изображения может варьироваться от 108 до 1967 пикселей, а высота от 80 до 1536 пикселей, отношение ширины к высоте лежит в диапазоне от 0.40 до 7.63, что говорит о присутствии среди изображений вертикальных кадров, а также панорамных снимков. Подобный разброс делает необходимым этап предварительной обработки изображений с целью приведения их к единому размеру, требуемому сверточными нейронными сетями.




Рис. 1: Перспективное искажение здания на фото.




Рис. 2: Геометрические характеристики изображений датасета.

### 3.3 Анализ распределения назначений зданий

Ключевые поля `type` (тип) и `type_alt` (альтернативный тип) содержат по 10 и 11 уникальных значений соответственно. Преобладающим значением для основного типа здания является `apartments` (жилое здание) — 5131 изображений, что составляет 31.8% от общего объема, вторая по численности категория — `office` (офисное здание) — 2541 (15.8%), замыкает тройку `house` (частный жилой дом) — 2160 (13.4%). Наименее часто встречаются `garage` (гараж) — 276 (1.7%) и `religious` (религиозные сооружения) — 665 (4.1%). Полное распределение по классам представлено на рисунке 3.




Рис. 3: Распределение назначения зданий по типам.

Такой сильный перекоп в распределении классов создает сложности для обучения модели для распознавания. Необходимо применить взвешенную функцию потерь или же озаботиться балансировкой классов, иначе предсказания модели будут смещаться в сторону отдельных видов зданий. Этот вывод согласуется с наблюдениями из исследования Ху Н. и соавторов [16], показавших, что в масштабе городской застройки обнаружение малочисленных стилей достигает точности 57.8%.

Важная особенность заключается в низкой согласованности основной и альтернативной меток для типа здания, так совпадение зафиксировано только для 99 пар меток из 16113, что составляет 0.6%. Одно и то же здание с одинаковой степенью обоснованности может быть отнесено экспертной оценкой к разным типам, что подтверждает высокую степень неоднозначности зрительного восприятия. Одним из решений может быть применение тепловых карт внимания Grad-CAM [12] и оценка вклада признаков SHAP [13], для проверки обоснованности ответов, как это было сделано в работе М. Tasir и М. Khalid при создании сети HistoNet [18].

### 3.4 Анализ распределения материалов отделки и несущих конструкций

Распределение по материалам фасадной отделки (Рисунок 4) отличается значительным преобладанием кирпичных стен (brick) — 5 961 изображение (37.0%) и оштукатуренных поверхностей (plaster) — 3 471 изображение, (21.5%). Доля современных материалов — остекления (glass) и металлической облицовки (metal) — составляет 12.9% и 5.4% (866 изображений) соответственно. Фасады из дерева (wood) насчитывают 780 изображений (4.8%), из природного камня (stone) — 898 (5.6%).




Рис. 4: Распределение материалов наружной отделки зданий.

Изучение материалов несущего каркаса (constr\_mat) показывает ещё более выраженное разделение: кирпич (brick, 38.6%) и железобетон (concrete, 36.1%) в сумме составляют почти 75% датасета. Стальной каркас (steel) занимает 17.5%, деревянный (wood) — 7.0%, а каменный (stone) — 0.8%. Согласованность основной и дополнительной разметок для материалов оказалась такой же низкой, как и для назначений зданий, т.к. определение материала несущих конструкций по внешнему виду здания является ещё более сложной задачей, более того — не всегда выполнимой. Основные признаки конструктивной схемы здания, по которой можно

было бы установить предположительный материал несущих конструкций не всегда ярко выражены.

Для проверки смысловой непротиворечивости данных был выполнен совместный анализ материалов отделки и года постройки. Полученные результаты подтверждают наличие устойчивых временных закономерностей: средний год постройки зданий с каменной отделкой — 1915 г., с кирпичной — 1932 г., с оштукатуренной — 1946 г. В свою очередь, современные материалы: стеклянные фасады — 1996 г., металлическая облицовка — 1993 г., бетонные поверхности — 1979 г. Данная связь означает, что модель, вероятно, сможет использовать текстурные и цветовые особенности материалов как маркер года постройки. Это согласуется с подходом, применённым в ResNet [6], где глубокие свёрточные слои показали способность улавливать тонкие текстурные различия.

### 3.5 Анализ этажности и поиск ошибочных значений

Распределение зданий по этажности (Рисунок 5) имеет выраженную правостороннюю асимметрию. Для приведения анализа к нормативной базе Российской Федерации здания были сгруппированы в категории согласно действующему СП 54.13330.2016 «Здания жилые многоквартирные» (актуализированная редакция СНиП 31-01-2003) [22]. В соответствии с данным сводом правил, а также положениями СП 42.13330.2016 «Градостроительство. Планировка и застройка городских и сельских поселений», этажность жилой застройки классифицируется следующим образом: малоэтажная — здания высотой до 4 этажей включительно; среднеэтажная — от 5 до 8 этажей; многоэтажная — от 9 до 25 этажей; высотная — свыше 25 этажей.

В соответствии с приведённой классификацией малоэтажные здания составляют большинство выборки — 62.4% (10051 объектов), среднеэтажные — 22.8%, многоэтажные — 12.9%, высотные — 1.9% (305 объектов).



Рис. 5: Распределение зданий по категориям этажности согласно СП54.

Рассмотрение средней этажности в разрезе назначений зданий (Рисунок 6) выявило ожидаемую иерархию: наиболее высокими являются офисные сооружения (среднее — 12.5 этажа), соответствующие верхней границе многоэтажной застройки, гостиницы (7.6 этажа) и многоквартирные жилые дома (6.5 этажа), попадающие в категорию среднеэтажных. Промышленные постройки, культовые сооружения и частные дома отличаются наименьшей этажностью — 1.8–2.2 этажа в среднем и относятся к категории малоэтажных зданий.





Рис. 6: Средняя этажность по типам зданий.

Также в датасете были обнаружены явно ошибочные значения для этажности зданий. Пять зданий в датасете имеют этажность 200 этажей, что очевидно является ошибкой. Ошибки сконцентрированы в классе офисных зданий и вероятно вызваны сбоями в автоматической разметке фреймворка OpenFACADES, подобные ошибки устраняются при ручной разметке в CVAT.

### 3.6 Статистика по годам постройки

Датасет охватывает строения с годом постройки от 1100 до 2023 годов, однако распределение имеет ярко выраженные всплески. Подобное сгущение вокруг круглых дат с высокой долей вероятности свидетельствует об округлении возраста построек на этапе автоматической разметки. Установить точную дату подавляющего большинства зданий не представляется возможным ввиду того, что такая информация не всегда доступна, особенно с зарубежных ресурсов.



Рис. 7: Распределение зданий по предполагаемому году постройки.

Средний год постройки — 1954 при среднеквадратическом отклонении 64.9 года. Размах между нижним и верхним квартилями (25-й процентиль — 1930 г., 75-й процентиль — 2000 г.) показывает, что половина всех объектов набора данных возведена в период с 1930 по 2000 год. Значительный перекос распределения в сторону XX–XXI веков (более 80% данных) означает, что исторические здания доиндустриальной поры (ранее 1800 г.) представлены очень малым числом экземпляров. Качество распознавания таких строений вероятно пострадает, эту проблему можно решить с помощью расширения датасета записями для строений тех лет.

### 3.7 Выводы по итогам исследовательского анализа данных

Проведённый исследовательский анализ данных позволяет сформулировать следующие выводы и требования:

1. Неоднородность входных данных. Снимки выполнены с разным разрешением и соотношением сторон, что делает обязательной предварительную обработку с приведением к единому типоразмеру.

2. Неравномерность распределения классов. Как в назначении зданий, так и в материале отделки, конструкций, так и в разделении по годам постройки наблюдается выраженная несимметричность. Необходимо использовать взвешенную функцию потерь.
3. Необходимость очистки данных. В данных обнаружены ошибочно присвоенные значения этажности, а также назначение многих зданий можно трактовать по-разному, требуется проверка.

## 4 Референсное решение (baseline)

### 4.1 Выбор модели

В качестве отправной точки для решения задачи многоклассового распознавания типов зданий по фотографиям фасадов была выбрана остаточная свёрточная сеть ResNet-50 [6]. Выбор обосновывается следующими причинами:

ResNet является одной из наиболее изученных и многократно воспроизведенных моделей. Несмотря на то, что модель можно назвать устаревшей в современных реалиях, она хорошо себя показала и может быть использована как нижняя граница для дальнейшего отслеживания результатов.

В открытом доступе есть предобученные веса на датасете ImageNet, включающем в себя 1.2 миллиона изображений и 1000 классов. Модель отлично справляется с выделением простых геометрических форм и текстур объектов, что позволяет дообучить классифицирующие слои под указанные типы зданий и не обучать модель с нуля, что особенно актуально при ограниченном наборе данных.

Для решения задачи по классификации зданий в контексте референсного решения была выбрана модель ResNet50 (веса IMAGENET1K\_V2 — одни из лучших доступных в библиотеке torch). Модель была модифицирована путем замены классифицирующей части или же головы (head) на блок

из 2-х частей:

- Слой Dropout (прореживание) — отключает во время обучения 30% нейронов в случайном порядке, что предотвращает переобучение на отдельных типах зданий и помогает справиться с дисбалансом классов (актуально по описанным в разделе 3 причинам).
- Линейный слой — вычисляющий блок, который сводит все к 10 выбранным типам зданий, представленным в разметке.

Общее количество настраиваемых параметров 23,5 миллиона. Для воспроизводимости результатов был зафиксирован seed (зерно) генератора псевдослучайных чисел, выбранный seed — 42.

## 4.2 Предобработка данных и обучение модели

На основании результатов исследовательского анализа данных (раздел 3) из обучающей выборки (16 113 изображений) были исключены 29 аномальных записей с этажностью свыше 50 этажей, возникновение которых связано со сбоями автоматической разметки на этапе работы фреймворка OpenFACADES [19]. Итоговый набор данных, содержащий 16 084 изображения, был разделён на обучающую (11 258 изображения, 70%), проверочную (2 413 изображения, 15%) и тестовую (2 413 изображения, 15%) выборки с сохранением исходного распределения классов (стратифицированное разбиение).

Предобработка изображений заключалась в масштабировании сторон изображения до 256 точек с последующей случайной обрезкой до 224 точек (для обучающей выборки) и центральной обрезки для тестовой и валидационной. Для повышения стабильности работы модели к данным обучающей выборки применены следующие способы расширения данных: случайное отражение по горизонтали с вероятностью 50% и цветовые искажения (изменение яркости, контрастности, насыщенности в пределах 20% и цветового тона в пределах 5%).

В разделах 3.3 и 3.4 был обнаружен сильный дисбаланс классов, в попытке снизить негативный эффект, были применены два взаимодополняющих метода выравнивания:

- Взвешенная функция потерь `CrossEntropyLoss` (Перекрестная энтропия) в которой вес каждого класса установлен обратно пропорциональным его частоте в обучающей выборке.
- Вероятностный выбор примеров с неравными весами (`Weighted Random Sampler`) при формировании обучающих пакетов. Данный подход изменяет частоту появления примеров различных классов, так примеры редко-встречающихся классов подаются модели чаще.

Обучение проводилось в течение 30 эпох с оптимизатором `AdamW` с начальной скоростью обучения  $10^{-4}$  и коэффициентом снижения весов (`weight decay`)  $10^{-4}$ , выполняющим роль L2-регуляризации. Для управления скоростью обучения применялся планировщик `ReduceLROnPlateau`, отслеживающий точность на проверочной выборке и уменьшающий шаг обучения вдвое при отсутствии улучшений в течение трёх эпох подряд. Для предотвращения переобучения использован механизм ранней остановки: семь эпох без прироста, однако в нашем случае остановка не сработала. Размер пакета (`batch size`) — 32 изображения.

### 4.3 Результаты baseline-модели

Точность на обучающей выборке монотонно возрастала на протяжении всех 30 эпох, достигнув значения 0.966 к концу обучения, что свидетельствует о способности модели успешно подстраиваться под предъявляемые данные. Потери на обучающей выборке при этом снизились с 1.203 (эпоха 1) до 0.038 (эпоха 30).

На валидационной выборке точность постепенно возрастала с 0.353 (эпоха 1) и вплоть до 0.702 (эпоха 28). При этом потери на валидационной

выборке достигли минимальных значений на эпохах 4–8 (около 1.21), а затем начали возрастать вплоть до 1.80 при растущей точности. Подобные показатели являются признаками переобучения, модель улавливает статистические закономерности, однако уверенность в новых предсказаниях снижается.

Итоговая оценка на тестовой выборке, которая не использовалась на этапе обучения и при подборе гиперпараметров, показала общую точность 71.8%. Данный результат находится в промежутке между умеренной точностью, зафиксированной Ху Н. и соавторами городской застройки Китая (57.8%) [16], и более высокой точностью свёрточных сетей в исторически однородных наборах данных [14]. Таким образом, выбранный подход с дообучением ResNet является отличным решением в качестве отправной точки.

Для различных классов наблюдается неоднородность качества распознавания (Рисунок 8), так наилучшие значения F1-score достигнуты для классов apartments (многоквартирный дом): F1 — 0.790, и house (частный дом): F1 — 0.768. Для более малочисленных классов, например office (офисное здание) — достигнута умеренная точность — 0.731.




Рис. 8: Матрица ошибок baseline-модели.

Наихудший показатель получен для здания с назначением education (учебное заведение), F1 — 0.480. Примечательно, что для класса garage (гараж) имеющего наименьшее число экземпляров и в обучающей, и в тестовой выборках модель выдала хорошие показатели: F1 — 0.744, precision — 0.784. Этот результат подтверждает действенность комбинации взвешенной функции потерь и вероятностного семплера, которые позволили модели выделить признаки редко-встречающегося класса.

## 4.4 Выводы по результатам baseline-модели

Результаты, полученные с baseline-моделью (ResNet-50 [6]) позволяют сформулировать следующие выводы:

1. Предобучение на ImageNet в сочетании с дообучением классифицирующей части обеспечило точность 71.8%, что является отличным базисом.
2. Дисбаланс классов не удалось преодолеть полностью, несмотря на применение взвешенной функции потерь и взвешенного случайного отбора, для отдельных классов получены значительно худшие метрики, чем для наиболее многочисленных.
3. Общее количество эпох обучения и число эпох до остановки при отсутствии улучшения были подобраны неверно, так как на поздних эпохах замечены признаки переобучения, о чем сигнализирует рост потерь на фоне роста точности на обучающей выборке.
4. Малочисленные классы с ярко-выраженными признаками распознаются хорошо, например garage (гараж).

Достигнутая точность (71.8%) оставляет значительный запас для совершенствования. В качестве оптимальных направлений для дальнейшего совершенствования можно выделить:

- а) замена head (головы), например на более глубокую с добавлением дополнительного полносвязного слоя с нормализацией;
- б) использование современной архитектуры (EfficientNet [7], Vision Transformers [10]);
- в) внедрение методов интерпретации (Grad-CAM [12], SHAP [13]) для анализа причин ошибок на классах education и public.



## 5 Предсказание множественных признаков

### 5.1 Выбор модели

Исходное решение (baseline) на основе ResNet-50 [6], рассмотренное в разделе 4, продемонстрировало точность 71.8% на задаче классификации типов зданий, однако выполненная разметка датасета и итоговая задача подразумевают предсказание множественных меток для каждого здания. Следовательно, для итогового решения требуется переход к многозадачному обучению (Multi-Task Learning, MTL). Многозадачное обучение позволяет решать несколько взаимосвязанных задач в рамках одной модели, что способствует как снижению вычислительных затрат, так и повышению обобщающей способности за счёт использования общих признаков [23].

В качестве архитектуры для многозадачной модели выбрана ConvNeXt-Base — современная свёрточная сеть, предложенная Z. Liu и соавторами в 2022 году [24]. ConvNeXt представляет собой результат модернизации классической архитектуры ResNet путём интеграции наиболее эффективных методик из области трансформеров: слой нормализации Layer Normalization вместо Batch Normalization, функция активации GELU (Gaussian Error Linear Unit, линейная единица ошибки Гаусса), разделённые свёртки с большими ядрами  $7 \times 7$  и улучшенная схема стема (patchify stem). Несмотря на то, что ConvNeXt имеет высокую преемственность с ResNet, его производительность сопоставима со Swin Transformer, при этом ConvNeXt остается полностью сверточной архитектурой [24].

Выбор ConvNeXt в версии Base (89 миллионов настраиваемых параметров) обусловлен наличием предобученных на ImageNet-21K весов, позволяющих не обучать модель с нуля, а лишь дообучить её, что особенно актуально при малом количестве данных. Вторая причина выбора именно версии Base — приемлемая вычислительная сложность, обучение моделей проводилось на GPU Nvidia RTX 5080 с 16 Гб видеопамяти, размер пакета — 32 изображения.

Архитектура многозадачной модели состоит из общей основы и специализированных голов (head), что является стандартной практикой для MTL-задач в компьютерном зрении [23]:

- Общая основа (backbone): ConvNeXt-Base без последнего классифицирующего (полносвязного) слоя. Извлекает вектор признаков размерностью 1024 из изображения.
- Шесть голов, выполняющих задачу классификации, состоящие из слоя Dropout и Linear аналогично решению из baseline. Единственный полносвязный слой выбран по причине того, что предобученная основа уже извлекает высокоуровневые признаки, и добавление дополнительных нелинейных преобразований поверх них часто приводит к переобучению при среднем размере датасета (10–50 тысяч изображений).
- Две регрессионные головы: состав тот же, что и у классификационных голов, однако линейный слой возвращает числовое значение года постройки или этажность.

Общие потери вычисляются как взвешенная сумма потерь по всем восьми задачам. Для классификационных задач используется взвешенный CrossEntropyLoss (веса обратно пропорциональны частоте классов), для регрессионных — MSELoss. Веса задач подобраны эмпирически с учётом их приоритета: основная задача по определению типа здания (type) имеет максимальный коэффициент 1.0, регрессионные задачи — 0.3–0.5, альтернативные метки — 0.3–0.5.

Все гиперпараметры обучения идентичны процессу обучения baseline-модели, оптимизатор AdamW ( $lr = 10^{-4}$ ,  $weight\_decay = 10^{-4}$ ), планировщик ReduceLROnPlateau ( $factor = 0.5$ ,  $patience = 3$ ), размер пакета (batch) — 32 изображения, изменен только параметр ранней остановки с 7 эпох на 5, ввиду избыточности столь долгого ожидания. Предобработка данных, аугментации (RandomCrop, RandomHorizontalFlip, ColorJitter)

и стратифицированное разделение на обучающую/проверочную/тестовую выборки полностью идентичны исходному решению.

## 5.2 Результаты многозадачного обучения

Обучение заняло 15 эпох, и завершилось срабатыванием ранней остановки после 5 эпох без улучшения. Лучшая модель сохранена с максимальной точностью на валидационной выборке в 71.6% и 72.9% на тестовой выборке, итоговые результаты приведены в таблице 1. Динамика прироста точности на валидационной выборке в сравнении с baseline-решением приведена на рисунке 9. Динамика обучения показывает, что более современная модель быстрее адаптируется к новым данным и показывает более высокую эффективность.




Рис. 9: Динамика обучения baseline и multi-task моделей.

Таблица 1: Сводные результаты Multi-Task модели на тестовой выборке

| Задача          | Тип                        | Основная метрика | Значение           |
|-----------------|----------------------------|------------------|--------------------|
| type            | Классификация (10 классов) | Accuracy         | 0.729              |
| type_alt        | Классификация (11 классов) | Accuracy         | 0.514              |
| surface_mat     | Классификация (8 классов)  | Accuracy         | 0.832              |
| surface_mat_alt | Классификация (7 классов)  | Accuracy         | 0.576              |
| constr_mat      | Классификация (5 классов)  | Accuracy         | 0.861              |
| constr_mat_alt  | Классификация (7 классов)  | Accuracy         | 0.687              |
| age             | Регрессия (1100–2023)      | MAE / $R^2$      | 20.70 лет / 0.679  |
| floors          | Регрессия (1–50)           | MAE / $R^2$      | 1.24 этажа / 0.868 |

### 5.2.1 Определение типа здания

Точность классификации типов зданий составила 72.9%, что на 1.1% выше, чем для baseline-решения (ResNet-50, 71.8%). По результатам проверки работы модели на тестовой выборке в разрезе отдельных классов выявлена схожая с baseline картина с рядом улучшений. Наилучшие значения F1-меры достигнуты для классов religious (F1 — 0.881, precision — 0.914) и apartments (F1 — 0.776, precision — 0.921). Наихудшие — для public (F1 — 0.577, precision — 0.500) и education (F1 — 0.582, precision — 0.623).

При сравнении baseline-решения и итогового решения наблюдается при-

рост по 6 классам из 10 (Рисунок 10). Наибольший прогресс достигнут для religious (+0.100: с 0.781 до 0.881) и retail (+0.056: с 0.662 до 0.718). Снижение зафиксировано для apartments (−0.018), garage (−0.030), hotel (−0.076) и industrial (−0.034).

Матрица ошибок (Рисунок 11) показывает, что характер ошибок немного изменился в сравнении с baseline-решением. В многозадачном решении наиболее проблемными стали education или industrial (14.6%) и hotel или office (19.8%). Перераспределение ошибок может указывать на то, что модель стала лучше выделять признаки, отличающие эти классы от других, но не между собой, что обусловлено визуальной схожестью этих типов зданий.

Прирост точности на 1.1% по сравнению с ResNet-50 при одновременном решении ещё семи задач свидетельствует об эффективности как архитектуры ConvNeXt, так и многозадачного подхода в целом. Общие признаки, извлечённые для классификации материалов и оценки этажности, действуют как дополнительный регуляризатор, помогая и основной задаче [23].




Рис. 10: Сравнение F1-score рассмотренных моделей.




Рис. 11: Матрица ошибок multi-task модели.

### 5.2.2 Материалы отделки и конструкции

Классификация материалов показала наиболее высокие результаты среди всех задач: 83.2% для отделки (surface\_mat) и 86.1% для конструкции (constr\_mat). Кирпич (brick) распознаётся с F1 — 0.917 для отделки и F1 — 0.903 для конструкции — это наивысшие показатели среди всех классов и задач. Стекло (F1 — 0.792), штукатурка (F1 — 0.838) и бетон (F1 — 0.849 для конструкции) также классифицируются хорошо. Матрицы ошибок для обеих задач не содержат выраженных систематических смещений

для `surface_mat`, однако для пары `stone` и `brick` (камень и кирпич) в `constr_mat` присутствует систематическая ошибка, что в первую очередь объясняется схожестью конструктивных схем и примерно сопоставимыми годами постройки зданий из этих материалов. Высокое качество классификации материалов отделки объясняется устойчивыми текстурными и цветовыми характеристиками, хорошо улавливаемыми свёрточными слоями.

Альтернативные метки (`type_alt`, `surface_mat_alt`, `constr_mat_alt`) ожидаемо показали существенно более низкое качество: 51.4%, 57.6% и 68.7% соответственно. Это прямое следствие низкой согласованности основной и альтернативной разметок (совпадение не превышает 0.6%, как было показано в разделе 3).

Предсказание этажности показало высокие показатели, MAE (средняя абсолютная ошибка) — 1.24 этажа при  $R^2 = 0.868$  и RMSE (корень из среднеквадратической ошибки) = 2.13. Модель уверенно определяет этажность. Для года постройки средняя ошибка составила 20.70 лет при  $R^2 = 0.679$  и  $\text{RMSE} = 40.06$ . Учитывая приблизительный характер самой разметки, данная точность представляется приемлемой: модель уверенно отличает историческую застройку от современной, но ошибается в пределах одного архитектурного периода.

### 5.3 Интерпретация решений модели с помощью Grad-CAM

Одним из ключевых преимуществ свёрточных архитектур перед трансформерными является возможность использования методов визуализации областей внимания без модификации структуры модели. Для интерпретации решений многозадачной модели был применён метод Gradient-weighted Class Activation Mapping (Grad-CAM), предложенный R. Selvaraju и соавторами [12]. Grad-CAM использует градиенты целевого класса по отношению к активациям последнего свёрточного слоя для построения тепловой карты, показывающей, какие области изображения внесли наибольший вклад

в предсказание.

Визуализация проводилась на последнем свёрточном слое общей основы ConvNeXt-Base. Поскольку модель возвращает словарь выходов для восьми задач, а Grad-CAM ожидает на входе тензор, была реализована программная обёртка SingleTaskWrapper, направляющая градиенты только от выбранной задачи. Анализ проводился в трёх разрезах: проблемные классы, классы-лидеры и сравнение правильных и ошибочных предсказаний.

### 5.3.1 Проблемные классы

Для класса public ( $F1=0.577$ ) при правильном предсказании (Рисунок 12а) тепловая карта показывает, что модель фокусируется на больших объемах сплошного остекления (витражей), характерных для офисных зданий, а также на массиве симметрично расположенных окон, что тоже бывает характерно для офисных зданий. Однако при ошибочном предсказании (Рисунок 12в), когда реальный класс «retail», а модель ошибочно отнесла здание к классу «public», мы видим, что модель распознала остекление и входную группу, однако потеряла нужный контекст в виде вывески, которая на этом фото видна не полностью. Такие ошибки характерны при недостаточном количестве данных с аналогичной композицией.



Рис. 12: Тепловые карты внимания Grad-CAM: а — верно распознанный класс «public», б — верно распознанный класс «education», в — неверно распознанный «public».



Для класса «education» ( $F1=0.582$ ) тепловые карты (Рисунок 12б) схожи с тепловыми картами «public», модель фокусируется на аналогичных элементах фасада, например, на массивах окон. Если проанализировать тепловые карты для «public» и «education» можно найти множество схожих паттернов, воспринимаемых моделью, что согласуется с системной ошибкой в определении этой пары классов. В условиях Санкт-Петербурга и европейской застройки старые здания общественного и образовательного назначения в основном расположены в идентичном фонде застройки, этим обуславливается сложность выделения уникального паттерна для каждого из этих назначений, особенно на малых данных.

### 5.3.2 Лучший класс

Для класса apartments ( $F1=0.776$ ), стабильно входящего в число лидеров по качеству распознавания, тепловая карта (Рисунок 13) четко демонстрирует области внимания, сосредоточенные на балконах и сетках окон. Локализация внимания на этих архитектурных элементах объясняет высокую точность классификации: балконы и регулярный ритм оконных проёмов являются устойчивыми визуальными маркерами, редко встречающимися в других категориях.




Рис. 13: Тепловые карты внимания Grad-CAM для класса «apartments».

### 5.3.3 Классификация материалов

Визуализация Grad-CAM для задачи `surface_mat` подтвердила, что модель опирается на текстурные признаки. Для кирпичной отделки (brick,  $F1=0.917$ ) тепловая карта показывает равномерное покрытие больших фрагментов стены с отдельными ярко выраженными участками — модель изучает поверхность фасада, выделяя характерный рисунок кирпичной кладки. Для стеклянных фасадов (glass,  $F1=0.792$ ) внимание концентрируется на бликах и отражениях, покрывая значительную часть остеклённой поверхности. Серьезных систематических ошибок не обнаружено, а высокая общая точность классификации материалов свидетельствует о высокой надежности механизмов выявления текстурных особенностей изучаемых поверхностей.

## 5.4 Выводы по результатам Multi-Task модели

Проведённый анализ Grad-CAM позволяет сделать следующие выводы:

1. Модель опирается на архитектурно значимые элементы. Тепловые

карты подтверждают, что ConvNeXt-Base анализирует окна, балконы, входные группы и текстуры стен, а не случайные шумы или фон. Это обосновывает применение глубоких сверточных сетей для анализа архитектуры.

2. В редких случаях было замечено смещение фокуса внимания на объекты, не имеющие отношения к самому зданию. Также могу отметить возможность отнесения некоторых зданий к 2-м разным типам, например, если на 1-м этаже находится магазин, а на втором — жилая часть, так мы получаем сразу два класса: «retail» и «apartments».
3. Подтверждена визуальная схожесть некоторых классов. Для «education» и «public» Grad-CAM показывает активацию на одних и тех же участках фасада (окна, входные группы), что объясняет как трудность их идентификации и сложность в их различении друг от друга.
4. Классы с наилучшими показателями метрик лидируют благодаря уникальным признакам или их сочетаниям. Чёткая локализация внимания на балконах и регулярной сетке окон для «apartments» подтверждает, что модель находит и использует уникальные визуальные маркеры.

Итоги многозадачного решения. Переход от однозадачного ResNet-50 к многозадачному ConvNeXt-Base позволил одновременно предсказывать восемь атрибутов зданий, повысив точность классификации типов с 71.8% до 72.9%. Наилучшие результаты достигнуты для задач, опирающихся на текстурные признаки: классификация материалов отделки (83.2%) и конструкции (86.1%), а также предсказание этажности (MAE 1.24 этажа,  $R^2 = 0.868$ ). Данный результат подтверждает, что современные свёрточные архитектуры способны эффективно извлекать текстурные характеристики из уличных снимков даже при наличии шумов и искажений.

Наибольшие трудности вызвали задачи с высокой степенью субъективности разметки: альтернативные метки типов зданий (точность 51.4%) и альтернативные материалы отделки (57.6%). Grad-CAM показал, что в случаях ошибочной классификации модель может фокусироваться на объектах окружения, а не на архитектурных элементах самого здания или же терять контекст, выделяя слишком малую область и ошибочно определяя основной паттерн. Это указывает на принципиальное ограничение подхода, основанного исключительно на уличных снимках: без дополнительного контекста даже качественная модель не всегда способна отделить признаки самого здания от его окружения.

## 6 Заключение

В ходе выполнения выпускной квалификационной работы была решена задача автоматического определения атрибутов зданий по уличным фотографиям фасадов методами глубинного обучения.

Сбор и разметка данных. С применением фреймворка OpenFACADES и ручной корректировки в CVAT сформирован набор данных из 16 113 изображений с восемью целевыми признаками. Ключевой проблемой на данном этапе стала сложность поиска качественных уличных снимков и высокая трудоёмкость ручной верификации автоматической разметки. Уличные фотографии содержат перспективные искажения, окклюзии растительностью и транспортом, а также принципиально разное качество и разрешение. Кроме того, для значительной части зданий точный год постройки и материал несущих конструкций не могут быть достоверно установлены только по фотографии фасада. Всё это накладывает фундаментальные ограничения на достижимую точность классификации.

Референсное и итоговое решения. Реализована референсная модель на основе ResNet-50 (точность классификации типов зданий 71.8%) и итоговая многозадачная модель на основе ConvNeXt-Base, одновременно предсказывающая восемь целевых атрибутов. Точность классификации типов зданий

составила 72.9%. Многозадачный подход позволил одной моделью решать восемь задач без потери качества по сравнению с однозадачным решением.

Наилучшие результаты достигнуты для задач, опирающихся на текстурные характеристики поверхностей: классификация материалов отделки (83.2%) и конструкции (86.1%), а также предсказание этажности (MAE 1.24 этажа,  $R^2 = 0.868$ ). Это подтверждает, что современные свёрточные архитектуры способны эффективно извлекать информацию о текстуре даже из зашумлённых уличных снимков. Материалы — кирпич, стекло, штукатурка — обладают устойчивыми визуальными характеристиками, что делает их классификацию значительно более надёжной, чем определение функционального назначения здания или года постройки.

Применение Grad-CAM подтвердило, что модель опирается на архитектурно значимые элементы фасада: окна, балконы, входные группы и текстуры стен. Анализ ошибочных предсказаний выявил, что причиной ошибок часто является смещение фокуса внимания на объекты окружения, а также недостаточность видимой поверхности фасада здания, чтобы опираться на композицию целиком.

Для перехода к практически применимому решению требуется:

1. Расширение обучающей выборки за счёт экспертно-размеченных данных, включающих не только уличные снимки, но и изображения с контролируемых ракурсов в высоком разрешении с минимальными искажениями.
2. Оптимизация системы меток — расширение числа классов типов зданий с учётом региональной архитектурной специфики, уточнение категорий материалов и введение дополнительных архитектурных признаков (форма кровли, тип остекления и т.д.).
3. Поиск способа получения достоверных данных о годе постройки в массовом порядке. На текущем этапе физически невозможно запросить данные для всех рассмотренных строений.

4. Разработка ансамблевых решений, объединяющих сильные стороны свёрточных и трансформерных архитектур для дальнейшего повышения точности.

Результаты работы подтверждают принципиальную возможность автоматического определения атрибутов зданий по уличным фотографиям методами глубинного обучения и определяют направления для дальнейших исследований на пути к созданию практически применимых систем учета и документирования городской застройки.

## Список литературы

- [1] Lowe D. G. Distinctive Image Features from Scale-Invariant Keypoints // International Journal of Computer Vision. — 2004. — Vol. 60, no. 2. — P. 91–110.
- [2] Dalal N., Triggs B. Histograms of Oriented Gradients for Human Detection // 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05). — 2005. — Vol. 1. — P. 886–893. — DOI: 10.1109/CVPR.2005.177.
- [3] LeCun Y., Bottou L., Bengio Y., Haffner P. Gradient-based learning applied to document recognition // Proc. IEEE. — 1998. — Vol. 86, no. 11. — C. 2278–2324.
- [4] Krizhevsky A., Sutskever I., Hinton G. E. ImageNet Classification with Deep Convolutional Neural Networks // Advances in Neural Information Processing Systems 25 (NIPS 2012). — 2012. — P. 1097–1105.
- [5] Cruz-Roa A. A., Ovalle J. E. A., Madabhushi A., Osorio F. A. G. A deep learning architecture for image representation, visual interpretability and automated basal-cell carcinoma cancer detection // Lecture Notes in Computer Science. — 2013. — Vol. 8150 (Pt 2). — P. 403–410.
- [6] He K., Zhang X., Ren S., Sun J. Deep Residual Learning for Image Recognition // Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). — 2016. — P. 770–778.
- [7] Tan M., Le Q. V. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks // Proceedings of the 36th International Conference on Machine Learning (ICML). — 2019. — P. 6105–6114.
- [8] Simonyan K., Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition // 3rd International Conference on Learning Representations (ICLR). — 2015. — arXiv:1409.1556.

- [9] Demir G., Ozturk B., Akarun L. A deep learning approach to universal art style classification // Multimedia Tools and Applications. — 2021. — Vol. 80. — P. 9517–9543.
- [10] Dosovitskiy A., Beyer L., Kolesnikov A., Weissenborn D., Zhai X., Unterthiner T., Dehghani M., Minderer M., Heigold G., Gelly S., Uszkoreit J., Houlsby N. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale // 9th International Conference on Learning Representations (ICLR). — 2021. — arXiv:2010.11929.
- [11] Корчагин В.Д. Анализ современных SOTA-архитектур искусственных нейронных сетей для решения задач классификации изображений и детекции объектов // Программные системы и вычислительные методы. 2023. № 4. С. 73-87.
- [12] Selvaraju R. R., Cogswell M., Das A., Vedantam R., Parikh D., Batra D. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization // Proceedings of the IEEE International Conference on Computer Vision (ICCV). — 2017. — P. 618–626.
- [13] Lundberg S. M., Lee S.-I. A Unified Approach to Interpreting Model Predictions // Advances in Neural Information Processing Systems 30 (NIPS 2017). — 2017. — P. 4765–4774.
- [14] Sun M., Zhang F., Duarte F., Ratti C. Understanding architecture age and style through deep learning // Cities. — 2022. — Vol. 128. — Art. 103787.
- [15] Ren S., He K., Girshick R., Sun J. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks // Advances in Neural Information Processing Systems 28 (NIPS 2015). — 2015. — P. 91–99.
- [16] Xu H., Sun H., Wang L., Yu X., Li T. Urban Architectural Style Recognition and Dataset Construction Method under Deep Learning of street View Images: A Case Study of Wuhan // ISPRS International Journal of Geo-Information. — 2023. — Vol. 12, № 7. — Art. 264.



- [17] Gu A., Dao T. Mamba: Linear-Time Sequence Modeling with Selective State Spaces // First Conference on Language Modeling (COLM). — 2024. — arXiv:2312.00752.
- [18] Tasir M. A. M., Khalid M. N. A. A novel deep neural model for efficient and scalable historical place image classification // Scientific Reports. — 2025. — Vol. 15. — Art. 42745.
- [19] Liang S., Xie C., Zhao T., Stoffels R., Bielecki F. OpenFACADES: An open framework for architectural caption and attribute data enrichment from street-view imagery // ISPRS Journal of Photogrammetry and Remote Sensing. — 2025. — Vol. 230. — P. 918–942.
- [20] Verdoya D., Franco N., Tadi M. M., Zollo A. Deep Learning for Building Attribute Classification from Street-View Images for Seismic Exposure Modeling // Applied Sciences. — 2026. — Vol. 16, no. 2. — P. 875.
- [21] Yiannoudes S. Shaping Architecture with Generative Artificial Intelligence: Deep Learning Models in Architectural Design Workflow // Architectures. — 2025. — Vol. 5, no. 4. — P. 94.
- [22] СП 54.13330.2016. Здания жилые многоквартирные. Актуализированная редакция СНиП 31-01-2003 : свод правил : утверждён приказом Министерства строительства и жилищно-коммунального хозяйства Российской Федерации от 3 декабря 2016 г. № 883/пр : введён в действие 4 июня 2017 г. — Москва : Стандартинформ, 2017.
- [23] Crawshaw M. Multi-Task Learning with Deep Neural Networks: A Survey // arXiv preprint arXiv:2009.09796. — 2020.
- [24] Liu Z., Mao H., Wu C.-Y., Feichtenhofer C., Darrell T., Xie S. A ConvNet for the 2020s // Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2022. — P. 11976–11986.